

AI CODING MATURITY LADDER

企业级 AI Coding 成熟度模型

AI CODING MATURITY LADDER · ACML V1.0

L1-L5 五级进阶路径 · 每级 8 条硬门禁 · 第三方可核验
面向 CTO、研效负责人、Tech Lead 与咨询顾问

L1-L5 五级模型

8 条硬门禁 / 级

4 个质变点

短板原则

第三方可核验

“

AI Coding 的能力，不在模型，在规范。

TABLE OF CONTENTS

目录

ACML V1.0 · 2026 年 5 月

前言	
— 写在前面	一页速览 · 读法建议 002
PART I · WHY	
01 为什么需要这把尺	信息轰炸 · 自发评估 · 三类价值 · 预答辩 003
PART II · MODEL	
02 AI Coding 成熟度阶梯	设计原理 · 两条硬规则 005
图 L1-L5 成熟度全景图 · 四质变点时间轴	006
图 行业成熟度分布热力图	007
PART III · LEVELS	
03 五级详解	定位 · 现状 · 陷阱 · 门禁 · 路线图 008
L1 个人探索 · 个人用 · 无账目 · 组织未知	009
L2 企业试点 · 有授权 · 有资产 · 跨团队不动	011
L3 企业全面使用 · 常态化 · 有骨架 · 未进数据台阶	013
L4 量化驱动 · 数据驱动 · 决策重塑 · 飞轮闭环	015
L5 研发范式 · 被引用 · 被复现 · 在定义	017
PART IV · WHERE	
04 落地指南	自评方法 · SKILL Hub 时机 · 角色矩阵 · 快速自评工具 019
PART V · FUTURE	
05 新技术适用性与结语	框架稳定性 · 行动模板 023

写在前面

一页速览

AI Coding 成熟度阶梯用 L1-L5 五个级别描述 AI Coding 在企业里的成熟度。跨级要过"硬事实 + 硬指标"的晋级检查项，级别取决于最弱一条能力线（**短板原则**）。

L1-L5 一句话：

- **L1 · 个人探索：** AI Coding 只在个人层面，组织看不见也管不到。
- **L2 · 企业试点：** 有授权、有预算、有试点，但能力仍绑在试点团队里。
- **L3 · 企业全面使用：** 规范走到正式版、过半工程师日常使用，但数据尚未进决策。
- **L4 · 量化驱动：** 出现过一次因数据推翻原有判断的会议，数据真正进入决策。
- **L5 · 研发范式：** 方法论被行业引用、核心资产被外部独立复现。

进阶动作一句话：

- **L1 → L2（2-4 周）：** 拿合规许可、立试点预算、第一批资产入 Git。
- **L2 → L3（3-6 月）：** 搭 SKILL Hub、规范走到 v1.0、跨团队铺开、PR-Spec 关联率 70% 连续 8 周。
- **L3 → L4（6-12 月）：** DORA 与 AI 专属指标补齐、飞轮闭环、数据进管理层议程。
- **L4 → L5（12-24 月）：** 开源复现 + 社区输出 + 被引用验证。

读法建议

正文约 10000 字，按角色分两条路径：

- **CEO / CTO / 董办：** 写在前面 + Part 1 + L1-L5 每级前段 + Part 4 自评与角色矩阵，约 4000 字。
- **研效负责人 / Tech Lead / 咨询顾问：** 全文通读，10000 字。

Part 1 · 为什么需要这把尺

信息轰炸下的镜子

每周都有新东西。新的模型、新的 IDE、新的 Agent 框架、新的评测榜、新的 Benchmark、新的标准、新的行业报告。订阅号每天十几条推送，大会每月三四场，每一场都说"这是拐点"。行业不缺信息，行业被信息淹没。

信息多到一定程度，就不再是养分，而是噪声。工程师在加班看新模型的 RAG 评测，CTO 在会上被问"我们为什么还没上某某"，人力在讨论要不要专门招一批"AI 工程师"。每个问题都真实，但当问题的密度超过判断力，决策者开始跟着最近一条新闻改方向，团队跟着一起换齿轮。

这时候需要的不是"再一份报告"，是一把尺——能把眼前这些碎片信息定位到自己企业的位置上。看到一个新工具，能判断它动的是不是自己当前的短板；听到同行讲"我们 L3 了"，能判断那是真是假；团队里有人说"我们在某某方面不如对方"，能告诉他这事该现在办还是再等等。

尺不是为了比个高下，是为了在噪声里有个稳定参考点——知道哪里该动、哪里可以先不动。

大家其实已经在自发评估

评估早就开始了，只是没人说。

CTO 在季度会议上会被问"我们处在什么水平"，他心里要有个答案。Tech Lead 在团队内部周会上要回应工程师的焦虑——"别家都在用，我们为什么不上"，他也要有个答案。工程师私下讨论"我们公司这 AI 水准算几档"，每个人都有自己那把尺。合规在看别家有没有出事，人力在看同行招聘 JD 里出现了什么新岗位。

每个人都在评估，每个人都没说错。问题是——同一家公司里，CTO 说 L3，Tech Lead 说 L2，工程师说 L1。看上去在讨论同一件事，实际上用的不是同一把尺。

分歧不是由谁对谁错引起的，是由各自盯住的维度不同引起的。CTO 看的是预算、许可、对外交付的 PPT；Tech Lead 看的是团队内部的工具使用率和 PR 速度；工程师看的是手里那几个 Prompt 是否还好用。三把尺量三个面，得到的当然是三个答案。

这不是"要不要评估"的问题，是"要不要把这把尺对齐"的问题。没有对齐，讨论就永远绕在措辞里；对齐之后，讨论才真正开始。

Part 1 · 为什么需要这把尺

这把尺带来什么

把一把共同的尺放进组织，三类人会各自得到他们真正需要的东西。

对企业——有了一份能拿到董事会、拿给投资人、拿去向监管解释的结构化陈述。不再靠“我们有十几个试点项目”这种含糊说法，而是能说清“我们目前在 L2，短板在合规扩展与跨团队治理，下季度把 L2→L3 的 4 项门禁补齐”。风险披露、年度规划、并购估值，都有了一个和过去财务、IT、组织治理同级别的叙事层。AI Coding 从新闻话题，变成可管理的能力项。

对团队——Tech Lead 的规划不再是“把 AI 好好用起来”，而是“这季度把 PR-Spec 关联率从 40% 推到 70%，让四项核心指标的周报稳定 8 周”。预算申请、跨团队协作、招聘需求、甚至给工程师做绩效沟通，都有了一个共享的参照系。团队之间相互学习也变得可能——因为大家用同一套词在描述同一件事。

对个人——工程师第一次能清楚看到“这家公司现在处在哪、下一步要去哪、自己当前做的事对不对”。不再把 AI Coding 理解为“是不是有人学得比我快”，而是看清自己站在某个质变点之前还是之后。那些晚上刷到的新工具、新论文，现在有了归位的地方——属于当前短板就投入，不属于就先观察。

个人的焦虑大多来自没有参照系。一旦有了尺，焦虑会变成计划。

预答辩

四个最常见的疑问，提前回答：

一、又一个模型，有必要吗？ 有必要的地方不在“又多一个”，在“把已经在用的评估口径对齐”。反正评估在发生，不如让它用统一的词。

二、和 CMMI、DORA 重不重复？ 不重复。CMMI 度量软件过程成熟度，DORA 度量交付与运维效能，本模型度量的是 AI Coding 这一项组织能力。三者可以并用，不互相替代。

三、小团队也要 8 条门禁？ 可以精简，但判据不能松。小团队可以用更轻的证据形式（Issue、README、周会纪要），但“有没有”本身不能变成“差不多有”。

四、L4、L5 是不是人人都要冲？ 不是。多数企业的合理目标是稳定在 L3，L4、L5 是选择，不是义务。

Part 2 · AI Coding 成熟度阶梯

设计原理 · 为什么是 5 级

层级数不是拍脑袋定的，也不是照搬 CMMI。理由只有一条——**层级数等于质变点个数 + 1**。有几个必须跨越的分水岭，就有几级。

AI Coding 在企业里的落地，有四个清晰的质变点：

1. **个人** → **组织**。从工程师的个人技巧，变成组织名下的合规许可、预算与可共享资产。这一步迈不过去，AI Coding 不管谁用得有多熟，都只停在个别人的工位上。
2. **试点** → **全面**。从少数团队的封闭闭环，变成跨团队共用的资产与规范。难点是治理——没有 SKILL Hub 与 CODEOWNERS，规模化只是愿望。
3. **经验** → **数据**。从经验判断驱动决策，变成数据驱动决策。标志不是采了多少指标，而是有没有一次因一份数据推翻过原本的判断。
4. **跟随** → **定义**。从参考别家实践，变成方法论被行业引用、资产被外部复现。从追赶者变成定义者。

起点（L1 · 个人探索）+ 四次质变（L2 / L3 / L4 / L5），合为 5 级。每一级之间都有一条清晰的分界线——不是渐变，是跨越。

两条硬规则

模型有两条不能妥协的硬规则。

第一条 · 短板原则。 一家企业在本模型里的级别，取决于它最弱的那一条能力线——不取平均，不取最亮的点。一家公司 AGENTS.md 已经走到正式版、指标也采齐了，但合规许可只覆盖半数员工，那就还停在 L1 与 L2 之间，不是 L3。平均分是安慰自己的工具，短板才是真实。许多企业对外讲 L3、对内做 L1，根因就在拿亮点当整体。

第二条 · 晋级检查项。 从本级跨到下一级，必须同时具备**硬事实**与**硬指标**，并能被第三方核验。

- **硬事实**：一次事件、一个动作、一份文件——比如“管理层在季度评审里因某份数据推翻原有判断，会议纪要可查”。
- **硬指标**：一个数字、一条曲线——比如“PR-Spec 关联率 70%，连续 8 周”。
- **第三方可核验**：在 Git、PR、会议纪要、指标仪表盘、公开发布物中能查到——不是主观感受，不是周报措辞。

门禁的意义在于把主观感觉挡在外面。没有门禁的分级，只是另一种自我评估。

L1-L5 成熟度全景

级别由最弱能力线决定（短板原则）· 每级 8 条硬门禁 · 第三方可核验



四个质变点 · 每一级之间都是跨越，不是渐变



行业成熟度分布 · 你在哪里

基于与 50+ 家企业的培训与咨询交流整理。● 主要集中在 ● 少量分布 ○ 极少数

行业	L1	L2	L3	L4	L5
制造业	●	●	○	○	○
传统零售	●	●	○	○	○
政务 / 国企	●	●	○	○	○
金融 / 银行	●	●	●	○	○
头部互联网	○	●	●	●	○
头部科技公司	○	●	●	●	○
AI 原生公司	○	○	●	●	●
标准组织 / 开源	○	○	○	●	●

读法提示：同一家企业内部可能跨越多个级别——业务研发团队在 L1，金融科技子公司可能已到 L2。企业内部的短板线比行业均线更重要。不要用行业平均来安慰自己。

关键洞察 · 三个不对称

最拥挤

L2

有预算、有试点，但跨团队复用不动。金融与互联网行业的主要聚集地。

最合理的目标

L3

多数企业的合理终点。L4、L5 是选择，不是义务。

最常见误判

L1→L3

对外宣称 L3，Git 里的 AGENTS.md 仍是初版，只有试点团队在用。

Part 3 · 五级详解

L1-L5 是这把尺的刻度。每一节按同一结构展开：本级定位 → 典型现状 → 典型陷阱 → 晋级检查清单 → 行动路线图。门禁条目是本章核心——满足多少，就在哪里。

L1-L5 总览

每级一句话：

- **L1 · 个人探索**：AI Coding 只在个人与自发小组层面，组织看不见也管不到。
- **L2 · 企业试点**：有了授权、预算、试点团队和初步资产，但能力仍绑在试点团队里，跨团队不动。
- **L3 · 企业全面使用**：规范走到正式版、研发中心过半工程师日常使用，能力长进组织骨架，但数据尚未进决策。
- **L4 · 量化驱动**：DORA 与 AI 专属指标不只是采集，更是用于决策；出现过因数据推翻原有判断的会议。
- **L5 · 研发范式**：方法论被行业引用、核心资产被外部独立复现，组织从追赶者变成定义者。

进阶动作一句话：

- **L1 → L2**（2-4 周）：拿合规许可、立试点预算、第一批资产入 Git。
- **L2 → L3**（3-6 月）：搭 SKILL Hub、规范走到 v1.0、跨团队铺开、PR-Spec 关联率 70% 连续 8 周。
- **L3 → L4**（6-12 月）：DORA 与 AI 专属指标补齐、飞轮闭环、数据进管理层议程。
- **L4 → L5**（12-24 月）：开源复现 + 社区输出 + 被引用验证。

I L1 · 个人探索

本级定位

AI Coding 只存在于个人与自发小组层面，组织看不见也管不到。**关键词：个人用、无账目、组织未知。**

典型现状

组织层面，没有预算、没有合规许可、没有明确责任人；管理层对"谁在用什么工具、产出了什么"并不掌握；一旦出现 AI 相关风险事件，第一反应往往是"公司里怎么会有人用这个"。

团队层面，没有统一的 AGENTS.md、Landing Zone 或共享 SKILL；各人按自己的习惯调用工具；会议上偶尔有人分享，但没有沉淀机制，讲完就散。

个人层面，一部分工程师已经用得相当熟——个人账号订阅、自己写 Prompt、自己攒技巧；经验靠口口相传、私信发 Prompt、临时拉群。

指标层面，几乎没有有效指标。能统计出"哪些人在用"就已经算不错，更谈不上使用深度、产出效果、合规风险。

典型陷阱

这一级最常见的两个陷阱：

一是合规盲区。 工程师把内部代码、业务数据贴进公网工具，管理层不知道、安全团队不知道、合规团队也不知道。事故没发生时相安无事，一旦发生，责任和影响都很难界定。

二是英雄依赖。 团队里几个用得好的成了"AI 顾问"，新人有问题就去私信问，经验随人走。一旦这几位离开或换岗，团队立刻回到原点。

L1 · 个人探索

晋级检查清单

L1 → L2 晋级检查清单

- 组织层面有明确的 AI Coding 书面合规许可（可查阅的文件或公告）
- 有专门预算，至少覆盖试点团队的工具许可、培训与资产建设
- 管理层指定了至少 1 个试点团队，试点范围、时长、目标写入文件
- 试点团队产出初版 AGENTS.md，并进入 Git 仓库版本管理
- 试点团队至少有 1 套可共享的 SKILL / Rules，团队内已跑通一次完整闭环
- 搭好 Landing Zone 最小雏形（项目骨架 / 规范入口 / 评审流程 3 项起步）
- 建立基础使用统计——谁在用、用在哪类任务、周频次（手工即可，不要求自动化）
- 试点团队有固定复盘节奏，复盘记录进入组织可访问的位置

核验口径：以上条目须能在合规文件、预算记录、Git 仓库、会议纪要中被第三方核验。

进阶动作 · 行动路线图

L1→L2 常见节奏 2–4 周，最长 8 周。动作不多，但必须有人推——推动者多半是第一个把 AI Coding 带进公司的那个人。

主线一 · 拿到合规牌照（第 1–2 周）：找法务、安全、合规谈一次，把工具选型、数据边界、代码外传约束写成一页文件，走内部签字流程。拿不到许可，后面的事都不能名正言顺。

主线二 · 立预算、定试点（第 2–4 周）：向管理层要一笔试点预算，圈定 1 个愿意投入的业务团队作为起点；明确写清试点范围、时间窗、成功判定口径。不要贪多团队，第一批只需一个跑得通。

主线三 · 第一批资产入库（第 3–6 周）：让试点团队在日常任务里产出初版 AGENTS.md、一套共享 SKILL、Landing Zone 最小雏形；关键是“放到 Git 里、不再是谁电脑里的私货”。

难点不在技术，在开口——向合规要许可、向管理层要预算。许多团队卡在 L1 数年，不是做不到，是没人愿意当那个开口的人。

I L2 · 企业试点

本级定位

AI Coding 已经成为组织的事，但能力仍然绑在试点团队里，跨团队复用几乎不存在。**关键词：有授权、有资产、跨团队不动。**

典型现状

组织层面，公司拿到了正式预算和书面合规许可，1-3 个团队被指定为试点，季度汇报里有了 AI Coding 的固定议题，管理层第一次把这件事写进年度 OKR。

团队层面，试点团队产出了初版 AGENTS.md、Landing Zone、团队级 SKILL / MCP / Rules，周会里会专门留时间讲进展，Spec Coding 在内部跑通了若干闭环，团队内部用得顺手。

个人层面，试点团队里的工程师形成了习惯，手里有几个个人 SKILL；其它团队的工程师基本在围观，偶尔私下借用试点团队的 Prompt，不上台面。

结果层面，ROI 说不清，预算每个季度都要重新解释一次；非试点团队的态度是——等你们试成了，我们再说。

典型陷阱

这一级最常见的两个陷阱：

一是 SKILL Hub 建成了没人用。 Hub 搭好了，库里躺着几十个 SKILL，但绝大多数调用集中在少数几个，长尾零调用。根因是 Hub 没治理、没有评审流程、没人负责下架低质资产。

二是试点成功、规模化失败。 试点团队跑得漂亮，但资产里写的是团队自己的业务黑话、用的是团队自己的数据源，其它团队拿不走。试点变成孤岛，而不是样板。

L2 · 企业试点

晋级检查清单

L2 → L3 晋级检查清单

- SKILL Hub 三层治理（团队级 / 项目级 / 个人级）正式上线，项目级走 PR 与 CODEOWNERS 评审
- AGENTS.md、Landing Zone、核心 Spec 模板版本走到 v1.0 正式版，采用语义化版本号，变更走评审
- 至少 3 个团队共用同一套 AGENTS.md 与至少 5 个 SKILL（Git 历史可查）
- PR-Spec 关联率达到 70% 以上，连续 8 周稳定
- 四项核心指标（PR-Spec 关联率 / SKILL 调用次数 / AI 代码评审通过率 / 团队参与度）稳定周月报
- Hub 有季度 Review 机制，低调用资产按规则下架或归档
- 新员工入职两周内能独立跑通一次 Spec Coding 闭环
- 合规许可从“试点范围”扩展到“研发中心全员”

核验口径：以上条目须能在 Git、PR、会议纪要、指标看板中被第三方核验，主观陈述不作数。

进阶动作 · 行动路线图

，常见节奏 3-6 个月，不顺利会拖到 12-18 个月。三条主线并行推进。

主线一 · SKILL Hub 落地（第 1-3 月）：搭好三层治理结构，项目级走 PR 与 CODEOWNERS 评审；把试点团队里被反复引用的 Prompt、Rules、MCP 收编为项目级资产，业务黑话改为中性描述；建立季度 Review 与下架机制。

主线二 · 规范正式化（第 2-4 月）：AGENTS.md、Landing Zone、核心 Spec 模板从 v0.x 走到 v1.0，采用语义化版本号，变更走评审。规范从试点团队的文档升级为组织制度。

主线三 · 跨团队铺开（第 3-6 月）：挑 2-3 个非试点团队作为首批接入方，用真实任务验证资产迁移性；同步启动四项指标的周月报，进入 L3 前需稳定运行 8 周以上。

难点不在技术，在治理节奏——Hub 推得太快会淹没采纳、太慢会让试点团队重回单干。关键是让首批接入方在第 2 个月底看到收益。

L3 · 企业全面使用

本级定位

规范走到正式版、SKILL Hub 完成分级治理、研发中心过半*工程师在日常任务中使用，能力从试点团队扩散到组织骨架。**关键词：常态化、有骨架、尚未进入数据台阶。**

* "过半"为参考口径，实际比例可按企业规模、团队结构自行定义，不同组织可设不同阈值。

典型现状

组织层面，AI Coding 从试点变成常态，写进年度研发纲要；合规许可从试点范围扩展到全员；新员工入职培训里有 AGENTS.md 与 SKILL Hub 的独立模块。

团队层面，Spec Coding 成为新项目的默认范式，老项目改造也在分批对齐；AGENTS.md 有语义化版本号，Landing Zone 六板块齐全，变更走 PR 与 CODEOWNERS 评审。

个人层面，工程师在日常任务中使用 AI Coding，手里的 SKILL 从调用者变成贡献者，Rules 的每次迭代都有个人名字留在提交记录里，能力不再集中在某几个人。

指标层面，PR-Spec 关联率、SKILL 调用次数、AI 代码评审通过率、团队参与度这四项有稳定的周月报。

典型陷阱

这一级最常见的两个陷阱：**一是看板起来了但没人因它改过决策**——指标采集齐了、周报月报也在发，但管理层评审还是看定性汇报、看故事，没有一次因一组数据而推翻过原有判断。**二是新员工培训跟不上能力成长速度**——AGENTS.md 每周都在迭代，但入职材料还是三个月前的版本，新人上手前两周仍在踩已经被修过的坑。能力长出来了，传承没跟上。

L3 · 企业全面使用

晋级检查清单

L3 → L4 晋级检查清单

- DORA 四项（部署频率 / 变更前置时间 / 变更失败率 / 恢复时间）全部接入采集；轻量替代口径：至少覆盖"部署频率"与"故障恢复时间"两项，其余两项可用等效代理指标（如 PR 合并周期、线上回滚次数）
- AI 专属六项（上下文命中率 / 幻觉率 / Spec-Code 一致性 / AI 代码拒审率 / Prompt 复用深度 / AI 事故恢复时长）全部接入采集；轻量替代口径：中小团队可先覆盖前三项，其余三项在 L4 稳定后补齐
- 上述指标连续滚动采集 8 周以上，进入多维度仪表盘（轻量替代：手工周报 + 共享表格，不强制自动化看板）
- 至少跑通 1 次完整 A/B 实验（方法论变更 vs. 原方法论论），结果落回规范
- 飞轮机制跑通：使用资产的工程师中有明确比例反过来贡献 SKILL 与 Rules（季度可核查）
- AI Coding 指标进入管理层季度评审固定议题
- 出现过至少一次因一份数据而推翻原有判断的管理层评审会议（纪要可查）
- 新员工入职培训材料与 AGENTS.md 正式版本同步迭代，滞后不超过 2 周
- 老项目对齐率达到 70% 以上

核验口径：以上条目须能在 Git、PR、会议纪要、指标仪表盘中被第三方核验。

进阶动作 · 行动路线图

L3→L4 常见节奏 6–12 个月。关键不是多采几项指标，而是让数据真的改变决策。

主线一 · 指标补齐（第 1–3 月）：把 DORA 四项与 AI 专属六项全部接入采集，进入仪表盘；连续滚动至少 8 周，才具备进入决策的信度。

主线二 · 飞轮闭环（第 2–5 月）：让使用资产的工程师反过来贡献 SKILL 与 Rules，季度 Review 公示贡献榜、项目级评审向贡献者倾斜。资产越用越多、越磨越精，才是长进组织的标志。

主线三 · 数据进议程（第 4–8 月）：把 AI Coding 指标写入管理层季度评审固定议题，至少出现一次因一份数据推翻原有判断的决策——这是 L3 与 L4 最直接的分界。

难点不在技术、不在采集，在话语权——数据能不能在评审桌上和资深工程师的经验判断打个平手。只有当管理层真的习惯"看数据决定下一步"，这一跃才算完成。

L4 · 量化驱动

本级定位

决策从经验转向数据。DORA 与 AI 专属指标不只是采集，更是用于决策；出现过一次因数据推翻原有判断的会议，这一级才真正成立。**关键词：数据驱动、决策重塑、飞轮闭环。**

典型现状

组织层面，AI Coding 指标进入管理层季度评审的固定议题，预算分配、人员调配、项目优先级开始在数据上找依据；出过一次以上因数据推翻原有判断的评审会议。

团队层面，A/B 实验常态化，方法论变更先跑实验再写回规范；周会上工程师会主动引用仪表盘讨论 Spec、Rules 的迭代方向，讨论依据不再是“我觉得”。

个人层面，工程师不只是用资产，手里有大量 Rules / SKILL 的提交记录；Prompt 复用深度、资产贡献度等进入绩效评估维度，个人对组织资产的贡献被系统承认。

指标层面，DORA 四项与 AI 专属六项连续滚动 8 周以上，多维仪表盘与经营数据看板并列，是管理层看板的一级子页。

典型陷阱

这一级最常见的两个陷阱：

一是指标采全了但没进评审议程。 仪表盘漂亮，每月数据被整理进报告，但管理层评审上看的还是业务营收、项目里程碑，AI Coding 指标从没被引用来做一次决策。数据是装饰，不是工具。

二是 A/B 实验做完结果不落回规范。 实验跑了、结论有了，但规范没动、Rules 没改、新项目依旧按老方法来；实验变成一次性动作，不进入飞轮。

L4 · 量化驱动

晋级检查清单

L4 → L5 晋级检查清单

- 核心资产（SKILL 仓库、AGENTS.md、Landing Zone 模板中的若干项）以可用形式开源，有完整文档与许可证
- 有独立第三方企业成功复现其中至少一部分实践（可公开查证）
- 在行业标准组织、头部开源社区或旗舰技术大会形成至少 1 次正式方法论输出（演讲、白皮书、PR 被合入、标准条目被采纳等形式之一）
- 公开发布物（方法论稿件 / 开源仓库 / 标准文档）形成稳定更新节奏，至少维持 6 个月
- 同行业或跨行业企业主动引用本方法论作为自建起点（引用可公开查证）
- 内部指标与公开发布物之间有对应关系——外部可复现的部分，内部也在持续使用
- 开源社区 Issue 与 PR 响应有明确 SLA 且被执行
- 组织公开承担方法论升级责任，有对外披露的 Roadmap

核验口径：以上条目须能在公开发布物、社区记录、会议纪要、引用链接中被第三方核验。

进阶动作 · 行动路线图

L4→L5 常见节奏 12–24 个月。不是一条线跑通就到，是三条路径并行展开、最终合拢成一套可被外部复现的公共制品。

路径一 · 开源复现（第 1–12 月）：挑核心资产中被外部问得最多、迁移性最好的几项做开源准备，补许可证、补英文文档、搭社区通道；找 1–2 家对口企业做首批复现，记录问题回流到内部版本。

路径二 · 社区输出（第 1–12 月）：在标准组织、头部开源社区或旗舰大会推一篇方法论正式稿；对外讲的是方法论，不是产品；稿件要经得起同行评议的追问。

路径三 · 被引用验证（贯穿 12–24 月）：同行业或跨行业的新入行企业把这里的规范拿去作为起点——这是最慢、但最硬的证据。

难点不在技术，也不在资产质量，在耐心——外部复现与引用需要时间发酵。L4→L5 不再以“做得更好”为目标，以“可被复制”为目标。

I L5 · 研发范式

本级定位

方法论被行业引用、核心资产被外部独立复现，组织从追赶者变成定义者。**关键词：被引用、被复现、在定义。**

典型现状

组织层面，企业的 AI Coding 方法论在行业里有名字，在标准组织或头部社区有稳定话语权；新入行企业会把这里的规范当作起点；外部咨询与合作邀约常态化。

团队层面，核心团队既做内部研发，也是方法论的对外代言人；对外稿件经得起同行评议，参与行业标准制定；Maintain 开源仓库写进了岗位职责。

个人层面，工程师在行业社区有个人影响力，在公开大会上代表公司讲方法论；内部贡献与外部影响力挂钩，形成吸引同行人才的虹吸效应。

指标层面，除 L4 的内部指标外，还有外部指标——开源仓库的 Star / Fork / 被引用次数、社区活跃度、外部复现案例数。

典型陷阱

这一级最常见的两个陷阱：

一是开源了但无人复现。 资产放出去了、仓库也在更新，但 Star 多、PR 少，没有一家外部企业真正把它用起来。根因多半是开源时没做企业隔离——业务黑话、内部工具链、组织约定没清理干净，外部拿去就用不起来。

二是公开输出碎片化。 今年大会上讲一条线、明年白皮书写另一条线，核心叙事变来变去，外部看不懂这家企业到底在主张什么。

I L5 · 研发范式

本级验证清单

L5 没有"晋级"一说，但有"维持"。以下 8 条作为定期自查，任一失守即意味着本级已退化：

- □ 核心资产开源状态正常，有稳定的维护节奏与 SLA
- □ 连续 12 个月以上，有外部企业成功复现或引用的案例
- □ 方法论核心论断保持一致，公开输出之间可以互相印证
- □ 开源社区健康度（活跃 PR 数、Issue 响应时长、外部贡献者数）在健康区间
- □ 内部实践与公开版本对齐，不出现"对外讲一套、对内做一套"
- □ 组织公开 Roadmap 按节奏更新，承诺的事被兑现
- □ 行业标准组织 / 头部社区的输出没有断档超过 6 个月
- □ 方法论仍在迭代——L5 不是终点，是新起点

核验口径：以上条目须能在开源仓库、公开发布物、社区记录中被第三方核验。

进阶动作 · 持续投入

L5 没有下一级，进阶方向是**范式更新**——让这套方法论持续回应行业变化。三条主线长期并行。

主线一 · 方法论迭代：AI 工具、模型能力、行业实践每年都在变，方法论不能固化在发布那一刻。建议有明确版本节奏（如每 6 个月一次正式版）与变更评审机制，每次迭代都公开说明"动了什么、为什么动"。

主线二 · 社区经营：开源不是把代码扔出去，是经营一个社区——Issue 响应、PR 合入节奏、季度路线图、年度大会或线上分享，缺一不可。这是最长期、最容易被企业内部低估的投入。

主线三 · 下一代方法论储备：L5 的组织要有人在看下一个拐点——不只是把"当前方法论做得更好"，而是思考"下一个范式可能长什么样"。不做这件事，L5 会在某次行业变化中失守。

最大的风险是把 L5 当终点——一旦把方法论视作已完成，社区活跃度、外部引用、复现案例会随之衰减。L5 的维持靠的是持续更新，不是过去的成绩。

Part 4 · 落地指南

自评方法 · 3 步对号入座

不同行业集中分布的成熟度级别不同，做咨询前先看清这一件事。

- L1：制造业、传统零售、部分政务单位、部分国企研发中心。合规许可是最常见的拦路虎。
- L2：金融、头部互联网、头部科技公司。**最拥挤的一段**——有预算、有试点，但跨团队复用不动。
- L3：少数头部互联网与头部科技公司，多数是用 AI 做核心产品的公司。
- L4：极少数，全球范围内屈指可数。
- L5：零星，主要是在标准组织或头部开源社区有稳定话语权的那几家。

不要只看行业平均——同一家银行里，业务研发可能在 L1，金融科技子公司可能已经到 L2。企业内部的短板线比行业均线重要。

自评方法 · 对号入座

第一步 · 3 题定级

- 组织层面有没有正式合规许可和专项预算？没有 → L1；只到试点 → L2；全员覆盖 → L3 及以上。
- 资产是否跨团队共用？没有 → L1 / L2；至少 3 个团队共用同一套 AGENTS.md 与 SKILL（Git 可查）→ L3 及以上。
- 数据有没有进决策？没采集 → L1 / L2；采了但未进决策 → L3；出现过一次数据推翻判断的会议（纪要可查）→ L4 及以上。

三题结果取最低——短板原则。

第二步 · 定级校准 3 信号

- 自评 L3,实际停在 L2:跨团队共用看似齐了,但合规许可只到试点范围,或 PR-Spec 关联率从未连续 8 周达标。
- 对外宣称规模化、实际尚未出 L2:对外说"AI Coding 已全员部署",Git 里的 AGENTS.md 仍是初版,只有试点团队在用。
- 采了数据 ≠ 数据驱动:仪表盘漂亮,但管理层评审从未因一组数据推翻过原有判断——仍在 L3,不是 L4。

第三步 · 指向章节

定级完成后，直接去对应章节看"晋级检查清单"与"行动路线图"。下一步在哪，写得比任何咨询报告都直接。

提升优先级 · SKILL Hub 时机

每一级该做什么、不该做什么，有明确先后。搞错时机，投入越大越亏。

- **L1**：不建 Hub、不买大型平台、不立复杂度量体系。先做三件事——拿合规、立预算、第一批资产入 Git。过早建 Hub 只会得到一个没人提交的空仓库。
- **L2**：**黄金窗口期**。SKILL Hub 三层治理立起来，规范走到 v1.0，四项核心指标上线。L2 是整个模型里最难走、最容易半途而废的一段——多数企业卡在这里不是技术问题，是治理节奏。
- **L3**：治理深度比广度重要。DORA 与 AI 专属指标补齐、飞轮闭环、数据进管理层议程。不要急着开源——对外输出是 L4→L5 的事。
- **L4**：有选择地对外输出。稿件、开源、社区经营，任一条起步都可以，三条并行成本太高。

核心原则：每一级只做本级该做的事，不预支下一级的动作。

角色职责矩阵

一张表概括七个角色在 L1-L5 各级的主要职责（**E** 发起 / **X** 执行 / **V** 验收）：

角色	L1	L2	L3	L4	L5
CTO / CIO	E	E	V	V	E
研效负责人	—	X	E	E	X
Tech Lead	X	X	X	X	X
一线工程师	X	X	X	X	X
合规 / 安全	V	V	V	V	V
人力 / 培训	—	X	X	X	X
董办 / 战略	—	—	V	V	E

董办在 L5 的 E，指的是对外方法论输出的发起——方法论稿件、行业标准参与、开源战略由董办主导，CTO 不单独承担。

CTO 一系列变迁（其他列在详细版展开）：

- **L1 发起**：没有 CTO 签字，合规许可、试点预算都拿不到。关键动作是"开口"——向董事会讲清 AI Coding 是基础设施投入。
- **L2 发起**：CTO 亲自定义试点范围与成功口径，避免试点变成"跑个 demo 看看"。
- **L3 验收**：从发起人转为验收人，读四项指标周月报，不读 PPT。
- **L4 验收**：CTO 要敢在评审桌上说"这次按数据来"。
- **L5 发起**：CTO 再次成为发起人——对外输出、方法论迭代、范式建设。

企业 AI Coding 成熟度 · 快速自评

回答以下 8 题，系统自动给出当前级别与短板提示。结果取最低分项（短板原则），不取平均。

Q1 · 合规与预算

组织层面是否有正式的 AI Coding 书面合规许可，且有专项预算？

- ☐ 没有合规许可，也没有专项预算
- ☐ 有合规许可和预算，但仅覆盖试点团队
- ☐ 合规许可与预算已扩展到研发中心全员
- ☐ 全员覆盖，且预算分配依据 AI 指标数据

Q2 · 资产入库

AGENTS.md、SKILL / Rules 等核心资产是否进入 Git 版本管理？

- ☐ 没有，经验靠口口相传或私信
- ☐ 有初版，进了 Git，但只有试点团队在用
- ☐ 走到 v1.0 正式版，至少 3 个团队共用
- ☐ 有语义化版本号，变更走 PR 与 CODEOWNERS 评审

Q3 · 跨团队复用

AI Coding 资产（SKILL / AGENTS.md）是否被多个团队实际使用？

- ☐ 只有个别工程师在用，没有团队层面的共享
- ☐ 试点团队内部共享，其他团队基本在围观
- ☐ 至少 3 个团队共用同一套资产，Git 历史可查
- ☐ 全研发中心常态化使用，有飞轮贡献机制

Q4 · PR-SPEC 关联率

PR 与 Spec 的关联率是否达到 70% 并连续稳定 8 周？

- ☐ 没有统计，或从未达到 70%
- ☐ 偶尔达到，但不稳定
- ☐ 连续 8 周以上稳定在 70% 以上
- ☐ 稳定超过 70%，且进入管理层指标看板

Q5 · 指标采集

DORA 四项与 AI 专属指标的采集情况如何？

- ☐ 没有系统性指标采集
- ☐ 有基础使用统计（谁在用、用什么），但没有 DORA
- ☐ 四项核心指标有稳定周月报，DORA 部分接入
- ☐ DORA 四项与 AI 专属指标全部接入，连续滚动 8 周以上

Q6 · 数据进决策

AI Coding 数据是否真正影响过管理层决策？

- ☐ 没有数据，决策靠经验和感觉
- ☐ 有数据，但管理层评审还是看 PPT 和故事
- ☐ 数据进入季度评审议题，但尚未推翻过原有判断
- ☐ 出现过至少一次因数据推翻原有判断的评审会议（纪要可查）

Q7 · 新员工传承

新员工能否在入职两周内独立跑通一次 Spec Coding 闭环？

- ☐ 没有入职材料，靠老员工带
- ☐ 有材料，但版本滞后超过 1 个月
- ☐ 入职两周内能跑通，材料滞后不超过 2 周
- ☐ 入职材料与 AGENTS.md 同步迭代，有专项培训模块

Q8 · 对外影响力

方法论是否被外部引用或复现？

- ☐ 没有对外输出
- ☐ 有内部分享或小范围传播，尚未正式对外
- ☐ 有公开演讲或文章，但尚无外部复现案例
- ☐ 有独立第三方企业成功复现，或被行业引用（可公开查证）

计算我的成熟度级别

重置

Part 5 · 新技术适用性与结语

对新技术的适用性

这份模型最常被问的一个问题是——AI 技术变化这么快，明年出了新工具、新范式，这套尺还适用吗？

适用。原因是这把尺度量的是**组织能力**，不是工具。工具在变，AI Coding 在企业里要跨越的四个质变点没变——从个人到组织、从试点到全面、从经验到数据、从跟随到定义。这四条分界线不会因为换一个模型、换一个 IDE 而消失。

新技术来的时候，不是先问“要不要跟”，而是先对照本级清单问三件事：

- 它触及的是不是我当前的短板？ 是 → 投入；不是 → 进观察清单。
- 它会不会让现有门禁更容易跨？ 会 → 纳入进阶动作；不会 → 维持原计划。
- 它会不会改变某级的硬事实 / 硬指标定义？ 会 → 反馈给模型维护者，进下一个版本；不会 → 保持原判据。

框架不追着新闻改。模型的版本更新节奏是每 6 个月一次正式版——节奏本身就是判断。

结语

合上这份白皮书之后，把下面这句话写下来：

我们现在是 L_x，最短板是 P_x，下个季度做 3 件事：____、____、____，目标跨到 L_{x+1}。

这一句话填完，这份白皮书的任务就完成了。

这不是一个“看完收藏”的模型，是一个“写在周会上”的模型。贴在 CTO 的办公室墙上、写在季度 OKR 的首页、放进咨询报告的第一张 slide——都合适。

行业会继续喧嚣，新词会继续涌现。一把稳定的尺，让一家企业在这喧嚣里始终知道自己站在哪、下一步朝哪儿走。

这就是这份白皮书想做的事。

一把稳定的尺， 让企业知道自己 站在哪。

L1-L5 五级进阶路径 · 每级 8 条硬门禁

硬事实 + 硬指标 + 第三方可核验

短板原则 · 不取平均 · 不靠感觉



"AI Coding 的能力，不在模型，在规范。"

05

成熟度级别

L1 个人探索 → L2 企业试点 → L3 全面使用 → L4 量化驱动 → L5 研发范式

08

条门禁 / 级

硬事实 + 硬指标 + 第三方可核验，不取平均，短板决定级别

04

个质变点

个人→组织 · 试点→全面 · 经验→数据 · 跟随→定义

10K

字精读版

面向 CTO、研效负责人、Tech Lead 与咨询顾问的评估指南